

# Model drsečega povprečja z $n$ zakasnitvami

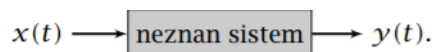
1. domača naloga pri Matematičnem modeliranju

Anže Mur

7. marec 2018

## 1 Opis problema

Imamo neznan sistem, ki nam pri vhodnem signalu  $x(t)$  vrne izhodni signal  $y(t)$ :



Naše podatke tvori  $N+1$  vhodov  $x_0, x_1, \dots, x_N$  in  $N+1$  pripadajočih izhodov  $y_0, y_1, \dots, y_N$ , ki jih izmerimo pri celoštevilskih časih  $t$  iz intervala  $[0, N]$ . Vhod in izhod sistema, ki pri vhodnem signalu  $x(t)$  vrne izhodni signal  $y(t)$  označimo:

$$x_i = x(i)$$

$$y_i = y(i)$$

Naš model predpostavlja, da lahko izhod  $y(t)$  ob času  $t$  zapišemo kot linearno kombinacijo  $n$  vhodov  $x(t), x(t-1), \dots, x(t-n+1)$  iz časovnega intervala  $[t-n+1, t]$  in tako dobimo enačbo:

$$y_k = h_1 x_{k-n+1} + h_2 x_{k-n} + \dots + h_{n-1} x_{k-1} + h_n x_k,$$

ki velja za vsak  $k = n-1, n, \dots, N$ . Imamo torej sistem  $N-n+1$  enačb z  $n$  neznankami  $h_1, \dots, h_n$  in predpostavljamo, da je  $N-n+1 \geq n$ . Z  $A$  označimo matriko tega sistema, s  $h = [h_1, \dots, h_n]^T$  pa vektor neznank in z  $y$  desno stran. Poiskati želimo rešitev sistema  $Ah = y$  v smislu linearne metode najmanjših kvadratov.

## 2 Naloge

**1. Naloga:** Izpelji in zapiši/opiši splošno obliko matrike  $\mathbf{A}$  in desne strani  $\mathbf{y}$ . Kako bi ob znanem  $\mathbf{h}$  napovedal izhod sistema  $y_0, \dots, y_m$ , če veš le, kaj so vhodni podatki  $x_0, \dots, x_m$ ? Katere komponente izhoda lahko napoveš?

**Rešitev:**

Matriko  $\mathbf{A}$  izpeljemo tako, da za  $x_k$  vstavimo vse  $k = [n-1, n, \dots, N]$ .

Izpeljava matrike  $\mathbf{A}$ :

$$\mathbf{A} = \begin{bmatrix} x_0 & x_1 & x_2 & \dots & x_{n-1} \\ x_1 & x_2 & x_3 & \dots & x_n \\ x_2 & x_3 & x_4 & \dots & x_{n+1} \\ \vdots & \vdots & \vdots & & \vdots \\ x_{N-n+1} & x_{N-n+2} & x_{N-n+3} & \dots & x_N \end{bmatrix}$$

Izpeljava matrike  $\mathbf{y}$  po sistemu  $A\mathbf{h} = \mathbf{y}$ , kjer je  $\mathbf{h}$  oblike  $\mathbf{h} = [h_1, \dots, h_n]^T$ .

$$\mathbf{y} = \begin{bmatrix} x_0 \cdot h_1 + x_1 \cdot h_2 + x_2 \cdot h_3 & + & \dots & + & x_{n-1} \cdot h_n \\ x_1 \cdot h_1 + x_2 \cdot h_2 + x_3 \cdot h_3 & + & \dots & + & x_n \cdot h_n \\ x_2 \cdot h_1 + x_3 \cdot h_2 + x_4 \cdot h_3 & + & \dots & + & x_{n+1} \cdot h_n \\ \vdots & & & & \vdots \\ x_{N-n+1} \cdot h_1 + x_{N-n+2} \cdot h_2 + x_{N-n+3} \cdot h_3 & + & \dots & + & x_N \cdot h_n \end{bmatrix} = \begin{bmatrix} y_{n-1} \\ y_n \\ y_{n+1} \\ \vdots \\ y_N \end{bmatrix}$$

Ob znanem  $\mathbf{h}$  bi in s podanimi vhodnimi podatki  $x_0, \dots, x_m$  izhod sistema  $y_0, \dots, y_m$  napovedal tako, da bi vhodne podatke pravilno vstavil v matriko sistema  $\mathbf{A}$  (po  $n$  podatkov v vsako vrstico, kjer bi  $n$  tekel od  $[n-1, N]$  in s tem premikal okvir velikosti  $n$  med vhodnimi podatki) in rešil sistem  $A\mathbf{h} = \mathbf{y}$ , kot je prikazano v zgornji izpeljavi matrike  $\mathbf{y}$ .

Komponente izhoda, ki jih lahko napovemo so  $y_{n-1}, \dots, y_N$ . Se pravi komponent z indeksom manjšim od  $n-1$  ne moremo napovedati.

**2. Naloga:** V octave-u napiši funkcijo  $h = \text{movavg}(x, y, n)$ , ki za vhodne podatke  $x = [x_0, \dots, x_N]$  in izhodne podatke  $y = [y_0, \dots, y_N]$  poišče koeficiente  $h = [h_1, \dots, h_n]$  za model drsečega povprečja z  $n$  zakasnitvami. (Upoštevaj specifikacije:  $x$ ,  $y$  in  $h$  so vrstice.)

**Rešitev:**

Nalogo rešimo tako, da najprej sestavimo matriko  $A$ , tako da iz vhodnih podatkov  $x$ , v vsaki iteraciji vzamemo okvir velikosti  $n$ , ter ga premaknemo za eno naprej, dokler ne pridemo do konca vhodnih podatkov  $x$ . Nato pa po metodi najmanjših kvadratov rešimo sistem.

**Rešitev v octave-u:**

---

```
function h = movavg(x, y, n)
%h = movavg(x, y, n) je funkcija ki za vhodne podatke x = [x0, ..., xN]
%in izhodne podatke y = [y0, ..., yN] poišče koeficiente
%h = [h1, ..., hn] za model drsečega povprečja z n zakasnitvami.
%x,y sta podana kot vrstična vektorja.

%sestavimo matriko A iz podatkov x, tako da vedno vzamemo
%okvir velikosti n iz vhodnih podatkov x,
%in ga v vsaki iteraciji premaknemo za eno naprej

for i = 1:length(x)-n+1;
A(i, :) = x(i : i+n-1);
end

%Resimo sistem po metodi najmanjših kvadratov
%in pri tem zanemarimo prvih n vrednosti y
h = A\((y(n:end))');
%v navodilih je napisano da mora biti h vrstični vektor
h = h';

%!test
%! x=[2 6 8 3];
%! y=[2 10 20 19];
%! h=[2 1];
%! n=2;
%! assert(movavg(x,y,n),h,eps*10)

%!test
%! x=[1 2 3 4 5 6 7 8 9 10];
%! y=[1 3 6 9 12 15 18 21 24 27];
%! h=[1 1 1];
%! n=3;
%! assert(movavg(x,y,n),h,eps*10)
```

---

**3. Naloga:** Recimo, da so vsi vhodi in izhodi konstantni, t.j.  $x_i = y_i = 1$ . Najprej ugani, nato pa še izpelji rešitev  $\mathbf{h}$  za poljubna  $N$  in  $n$ . Primerjaj z izhodom, ki ga vrne `movavg`.

### Intuitivna rešitev:

V primeru da so vsi vhodi in izhodi konstantni je vektor neznank sistema  $h$ , tudi konstantne vrednosti. Vektor  $h$  je sestavljen iz  $n$  elementov, ki imajo vrednosti  $\frac{1}{n}$ .

Naj bosta vhod izhod sestavljena iz neke konstantne vrednosti  $j$ , torej  $x_i = y_i = j$ . Rešitev sistema lahko uganemo, saj vemo, da mora biti vrednost, ki jo dobimo s seštevanjem  $n$  vrednosti vhoda  $x$  po množenju z vektorjem  $h$  enaka  $j$ . In ker je  $h$  vektor velikosti  $n$ , do iskane vrednosti  $y_i = j$  lahko pridemo samo tako da je  $h$  sestavljen iz  $n$  elementov vrednosti  $\frac{1}{n}$ .

Izpeljava vrednosti poljubnega elementa  $h$ ,  $h_i$ :

$$\begin{aligned} n \cdot x_i \cdot h_i &= y_i \\ h_i &= \frac{y_i}{n \cdot x_i} \\ h_i &= \frac{1}{n}; \quad \text{ker velja } x_i = y_i \end{aligned}$$

Oblika vektorja neznank  $\mathbf{h} = [\frac{1}{n_1}, \dots, \frac{1}{n_n}]$ .

Izhod funkcije `movavg` ustreza izpeljavi za računanje vrednosti vektorja  $h$ .

### Rešitev s pomočjo Moore-Penrose inverza:

Če imamo matriko  $A$ , ki je sestavljena iz samih enakih konstantnih vrednosti 1 in je velikosti  $m \times n$  vemo, da je njen MP inverz dimenzij  $n \times m$  in je sestavljen iz vrednosti  $\frac{1}{n \cdot m}$ . Spodnja izpeljava velja v primeru, če sta  $y_i = x_i = 1$ .

$$A = \begin{bmatrix} 1_1 & 1_2 & 1_3 & \cdot & \cdot & \cdot & 1_n \\ \cdot & & & & & & \\ \cdot & & & & & & \\ \cdot & & & & & & \\ 1_m & 1_{m+1} & 1_{m+2} & \cdot & \cdot & \cdot & 1_{mn} \end{bmatrix}; \text{ dimenzij } m \times n$$

$$A^+ = \begin{bmatrix} \frac{1}{n \cdot m} 1 & \frac{1}{n \cdot m} 2 & \frac{1}{n \cdot m} 3 & \cdot & \cdot & \cdot & \frac{1}{n \cdot m} m \\ \cdot & & & & & & \\ \cdot & & & & & & \\ \cdot & & & & & & \\ \frac{1}{n \cdot m} n+1 & \frac{1}{n \cdot m} n+2 & \frac{1}{n \cdot m} n+3 & \cdot & \cdot & \cdot & \frac{1}{n \cdot m} nm \end{bmatrix}; \text{ dimenzij } n \times m$$

$$h = A^+ \cdot y; \text{ kjer je } y_i = 1$$

$$h_i = \frac{1}{n \cdot m_1} + \dots + \frac{1}{n \cdot m_m}$$

$$h_i = \frac{1}{n \cdot m} \cdot m$$

$$h_i = \frac{1}{n}$$

**4. Naloga:** Napiši še funkcijo  $y = \text{prediction}(x, h)$ , ki iz vhodnih podatkov  $x$  in koeficientov  $h$  napove izhod  $y$  na podlagi našega modela.

#### Rešitev:

Nalogo rešimo tako, da najprej sestavimo matriko  $A$ , tako da iz vhodnih podatkov  $x$ , v vsaki iteraciji vzamemo okvir velikosti  $n$  (izračunamo ga iz dolžine vektorja  $h$ ), ter ga premaknemo za eno naprej, dokler ne pridemo do konca vhodnih podatkov  $x$ . Nato pa rešimo sistem  $y = A \cdot h$ .

#### Rešitev v octave-u:

---

```
function y = prediction(x, h)
%y = prediction(x, h) je funkcija, ki iz vhodnih podatkov x
%in vektorja koeficientov h napove izhod y na podlagi našega modela
%x in h sta podana kot vrstična vektorja
n = length(h);

for i = 1:length(x)-n+1;
A(i, :) = x(i : i+n-1);
end

y = A*h';

%!test
%! x=[1 2 3 4 5 6 7 8 9 10];
%! y=[6 9 12 15 18 21 24 27];
%! h=[1 1 1];
%! assert(prediction(x,h),y',eps*10)

%!test
%! x=[2 6 8 3];
%! y=[10 20 19];
%! h=[2 1];
%! assert(prediction(x,h),y',eps*10)
```

---

**5. Naloga:** Preveri delovanje na podatkih iz datotek **io-train.txt** in **io-test.txt** za  $n = 1, 2, 3, 5, 10$ . (io-train.txt je učni nabor, uporabi ga za izračun  $h$ . io-test.txt je testni nabor, napoved modela testiraj na podatkih iz tega nabora.) Kako je točnost napovedi odvisna od števila zakasnitev  $n$ ?

**Rešitev:**

Funkcijo **movavg** dopolnimo z demonstracijsko funkcijo **demo**, ki jo kličemo z ukazom: `demo movavg`. Ta iz učnih primerov prebere podatke in s pomočjo testnih primerov izračuna naš model, ter napake izračuna modela. Ob klicu funkcije se nam izrišejo tudi grafi napak, ter grafi primerjav  $y_{test}$  in  $y_{model}$  ob različnih zakasnitvah  $n$ .

**Dopolnitev funkcije movavg:**

---

```

%!demo
%! n=[1 2 3 5 10];
%! train_data = load("io-train.txt");
%! test_data = load("io-test.txt");
%!
%! x_train = train_data(1,: );
%! y_train = train_data(2,: );
%!
%! x_test = test_data(1,: );
%! y_test = test_data(2,: );
%!
%! count = 1;
%! for i = n
%!
%!     h = movavg(x_train, y_train, i);
%!     y_model = prediction(x_test, h);
%!     tmp = y_test-y_model;
%!     error(i) = norm(tmp);
%!     err1 = mean(abs(tmp), 1);
%!     abs_error(i) = mean(err1,2);
%!     figure(count)
%!     plot(y_test, 'g'); hold on; plot (y_model, 'r');
%!     title(['n = ' num2str(i) ''])
%!     legend("y_{test}", "y_{model}")
%!
%!     count = count + 1;
%!
%! end
%!
%! figure(6)
%! plot(n, error(n), 'r');
%! title("Napaka modela v odvisnosti od števila zakasnitev n")
%!
%! figure(7)
%! plot(n, abs_error(n), '-o');
%! title("Absolutna napaka modela v odvisnosti od števila zakasnitev n")

```

---

### Razlaga rezultatov dopolnjene funkcije movavg:

Pri tesnih  $n$ -jih je rezultat najbolj optimalen pri  $n=10$ , kjer je prileganje našemu modelu največje. Glede na naše rezultate, bi lahko sklepali, da se napaka modela s povečevanjem števila zakasnitev  $n$  začne zmanjševati. Vendar zaradi testnih primerov pri vrednostih, ko je  $n$  enak 1, 2, 3 in 5 vidimo, da temu ni res, saj se točnost napovedi ne povečuje, kljub temu da povečujemo  $n$ . Iz spodnjih grafov lahko razberemo, da je pri  $n = 5$  ujemanje veliko manjše kot pri manjših  $n$ -jih.

Pri  $n = 5$  napaka zelo poskoči. Taka odstopanja, bi se mogoče dalo omiliti, če bi za izračun modela uporabili Moore-Penrose inverz.

Pri velikih  $n$ -jih prihaja do odstopanj, ki pa absolutno ne variirajo v neke ekstremne vrednosti in odstopanja niso tako velika, vendar pa prileganje modela ni tako dobro, kot pri  $n = 10$ .




Figure 1: Absolutna napaka modela v odvisnosti od števila zakasnitev  $n$ .




Figure 2: Napaka modela v odvisnosti od števila zakasnitev  $n$ .




Figure 3: Prikaz  $y_{test}$  in  $y_{model}$  pri  $n = 1$






Figure 4: Prikaz  $y_{test}$  in  $y_{model}$  pri  $n = 2$




Figure 5: Prikaz  $y_{test}$  in  $y_{model}$  pri  $n = 3$




Figure 6: Prikaz  $y_{test}$  in  $y_{model}$  pri  $n = 5$




Figure 7: Prikaz  $y_{\text{test}}$  in  $y_{\text{model}}$  pri  $n = 10$

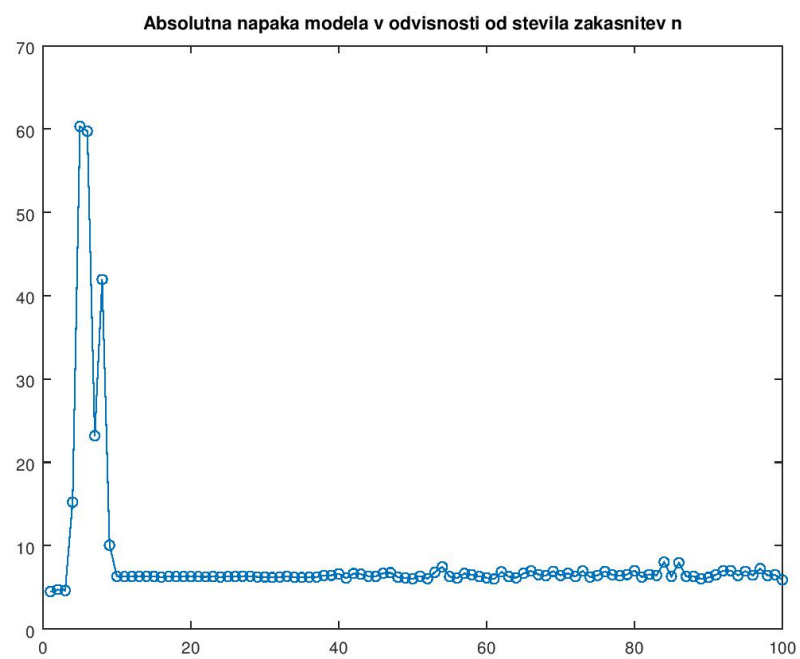


Figure 8: Absolutna napaka modela v odvisnosti od števila zakasnitev  $n$  na intervalu  $[1,100]$ .